Projet Masrvi

Assistant d'IA générative (RAG)

Recherche sur la documentation technique, fonctionnelle et les processus

Cahier des charges

À remettre après la phase d'apprentissage

Stack : Angular, Spring Boot, Qdrant, Ollama

Sommaire

1. Présentation du projet
2. Périmètre
3. Contraintes techniques
4. Principe de fonctionnement
5. Sources documentaires
6. Exigences fonctionnelles
7. Exigences non fonctionnelles
8. Déroulement indicatif
9. Critères d'acceptation
10. Livrables
11. Phase 2, en extension

1. Présentation du projet

Le projet consiste à développer un assistant qui répond en langage naturel à des questions portant sur la documentation de l'entreprise. L'utilisateur pose une question en français, l'assistant retrouve les passages pertinents dans la base documentaire, et rédige une réponse en s'appuyant sur ces passages, en citant ses sources.

La documentation couverte est large : documents techniques, documents fonctionnels, descriptions de processus, manuels d'instruction, et modèles de données (dictionnaires de données, schémas de base). Concrètement, on dépose des documents, par exemple un manuel d'instruction au format PDF, et l'assistant les indexe pour pouvoir répondre aux questions à leur sujet. L'objectif est de rendre cette connaissance accessible rapidement, sans avoir à chercher manuellement dans des dizaines de documents.

La méthode retenue est la génération augmentée par récupération, connue sous le nom de RAG. Le stagiaire a déjà suivi la phase d'apprentissage correspondante.

2. Périmètre

Le périmètre se divise en deux phases. La phase 1 est le cœur attendu. La phase 2 est une extension, abordée seulement si la phase 1 est terminée.

Phase 1, le cœur du projet

- Ingérer des documents fournis, notamment au format PDF, ainsi que des dictionnaires de données et des schémas.
- Découper les documents en passages et les indexer dans une base vectorielle.
- Rechercher les passages pertinents à partir d'une question.
- Générer une réponse fondée sur ces passages, avec citation des sources.
- Présenter le tout dans une interface web simple.

Phase 2, en extension si la phase 1 est terminée

- Reconnaissance de texte sur les PDF scannés, pour indexer aussi les documents non textuels.
- Gérer les permissions sur les sources, pour que chacun ne cherche que dans ce qu'il a le droit de voir.
- Prendre en charge le français et l'arabe.

3. Contraintes techniques

La pile technique est imposée.

- Interface : Angular.
- Backend : Spring Boot.
- Base vectorielle : Qdrant.
- Modèles d'IA : exécutés en local avec Ollama. Embeddings avec nomic-embed-text, génération avec un modèle léger adapté à une machine sans carte graphique.

Contrainte importante : les traitements d'IA restent en local. Aucune donnée ne doit sortir vers un service externe. Cette contrainte garantit que l'assistant pourra ensuite fonctionner sur la documentation réelle de l'entreprise.

4. Principe de fonctionnement

Deux temps se distinguent : la préparation des documents, puis la réponse aux questions.

Préparation :

> *Documents, puis découpage en passages, puis transformation de chaque passage en vecteur, puis stockage dans Qdrant avec ses métadonnées (document, page, section).*

Réponse :

> *Question en français, puis transformation en vecteur, puis recherche des passages les plus proches dans Qdrant, puis envoi de la question et des passages au modèle, puis réponse rédigée avec citation des sources.*

5. Sources documentaires

La base documentaire regroupe plusieurs natures de documents.

- Documents techniques : spécifications, notes, guides.
- Documents fonctionnels et descriptions de processus.
- Modèles de données : dictionnaires de données, schémas de base.

Les formats à prendre en charge en phase 1 incluent le PDF, ainsi que des formats texte simples comme le markdown et le HTML. Les dictionnaires de données arrivent souvent sous forme de tableaux dans des PDF, ce qui demande une extraction soignée.

Pendant le développement, le travail se fait sur un corpus de substitution non sensible. La documentation réelle de l'entreprise n'est pas utilisée à ce stade. Elle sera introduite plus tard, dans un cadre défini.

6. Exigences fonctionnelles

6.1 Ingestion des documents

- Extraire le texte des documents, y compris les PDF, avec les tableaux.
- Nettoyer le texte extrait (espaces, sauts de ligne, entêtes répétés).
- Conserver les métadonnées utiles : document d'origine, page, section.

6.2 Découpage en passages

- Découper chaque document en passages de taille adaptée, avec un léger chevauchement.
- Rattacher chaque passage à sa source et à sa position.

6.3 Indexation vectorielle

- Transformer chaque passage en vecteur avec le modèle d'embeddings local.
- Stocker les passages dans une collection Qdrant, avec leurs métadonnées.
- Permettre de recharger un corpus sans repartir de zéro à chaque fois.

6.4 Recherche

- Transformer la question en vecteur et retrouver les passages les plus proches.
- Régler le nombre de passages retenus et un seuil de pertinence.
- Pouvoir filtrer la recherche par source ou par type de document.

6.5 Génération de la réponse

- Construire un prompt qui donne au modèle la question et les passages retrouvés.
- Demander une réponse fondée uniquement sur ces passages, avec citation du document et de la page.
- Gérer le cas où aucune information pertinente n'est trouvée, pour éviter d'inventer.

6.6 Interface

- Une page de discussion : la question, la réponse, les sources cliquables.
- Un retour visuel pendant le traitement, car la génération peut prendre quelques secondes.

7. Exigences non fonctionnelles

- L'application fonctionne sur une machine sans carte graphique. La lenteur de génération est acceptée en développement.
- Aucune dépendance à un service d'IA externe.
- Le code est clair, commenté, organisé en fonctions.
- L'application ne plante pas sur une question sans réponse ou un document mal formé.

8. Déroulement indicatif

La phase d'apprentissage étant terminée, il reste environ trois semaines jusqu'à la fin du stage, prévue le 14 août 2026. Le plan ci-dessous tient dans ce délai. La priorité va à une chaîne complète qui fonctionne sur des PDF, même simple, plutôt qu'à des raffinements.

Semaine	Période	Contenu
1	22 au 28 juillet	Ingestion des PDF, extraction du texte, métadonnées (document, page). Découpage en passages. Indexation dans Qdrant avec les embeddings locaux.
2	29 juillet au 4 août	Recherche des passages pertinents. Génération des réponses sourcées. Première interface Angular de discussion.
3	5 au 14 août	Assemblage complet, tests sur un jeu de questions, corrections, documentation. Marge pour finir proprement.

Compte tenu du délai, l'extraction fine des tableaux complexes et la phase 2 ne sont pas prioritaires. Une chaîne qui répond correctement sur des PDF au texte lisible est l'objectif à atteindre en premier.

9. Critères d'acceptation

- Une question simple donne une réponse correcte, accompagnée de ses sources.
- Les sources citées indiquent le document et la page.
- Une question sans réponse dans le corpus n'entraîne pas de réponse inventée.
- Un PDF contenant des tableaux est ingéré sans perte majeure d'information.
- Le corpus peut être remplacé par un autre sans modifier le code.
- Aucune donnée n'est envoyée à un service externe.

10. Livrables

- Le code de l'application (ingestion, backend, interface).
- Le corpus de substitution et la procédure pour le remplacer.
- Un jeu de questions de test avec les réponses attendues.
- Une courte documentation : comment lancer, comment charger un corpus.

11. Phase 2, en extension

Ces sujets ne sont pas attendus au départ. Ils viennent seulement si la phase 1 est terminée et validée. Ils restent centrés sur les documents, sans analyse de code.

- Reconnaissance de texte sur les PDF scannés, pour indexer les documents qui ne contiennent pas de texte sélectionnable.
- Gestion des permissions sur les sources, en lien avec la sensibilité des documents réels.
- Prise en charge du français et de l'arabe.
- Amélioration de l'extraction des tableaux dans les PDF complexes, comme les dictionnaires de données.

Le développement se fait sur un corpus de substitution non sensible. La documentation réelle sera introduite plus tard, dans un cadre défini.